

Práctica 2: Chatbot con GEMINI (Modelo 2.5 Flash)

Objetivo: Utilizar la nueva SDK de Google (`google-genai`) para crear un asistente capaz de razonar profundamente.

Nota: La nueva SDK de Google tiene un objeto llamado `chats` que gestiona el historial automáticamente.

Diferencias Clave respecto al Chatbot con Groq:

1. Gestión de Memoria:

- En **Groq**, eres el responsable de crear una lista (`historial`), ir haciendo `.append()` de cada mensaje y enviarla entera en cada turno.
- En **Gemini** (SDK nueva), el objeto `chat_session` se encarga de recordar la conversación por ti mientras el programa esté corriendo. Solo usas `.send_message()`.

2. Configuración del Rol `system`:

- En **Groq**, el `system` es simplemente el primer diccionario de la lista `messages`.
- En **Gemini**, se define dentro del parámetro `config` como `system_instruction` al crear el chat.

Enlaces a la Documentación Oficial

- Portal Principal de Gemini API: ai.google.dev/gemini-api/docs
- Referencia Técnica de la Nueva SDK (GitHub Pages): googleapis.github.io/python-genai/ (Este es el lugar más preciso para ver los métodos de la librería `google-genai`).
- Repositorio de GitHub con Ejemplos: github.com/googleapis/python-genai

Explicación del parámetro Temperature

En el contexto de la Inteligencia Artificial (LLMs como Llama o Gemini), la **Temperatura** es un parámetro que controla el grado de **aleatoriedad** y **creatividad** de las respuestas del modelo.

Imagina que es un "dial" que ajusta qué tan arriesgada o conservadora es la IA al elegir la siguiente palabra.

¿Cómo funciona técnicamente?

Cuando una IA genera texto, no sabe "qué decir", sino que calcula **probabilidades**.

Si le pides que complete la frase: *"El cielo es..."*

- **Azul:** 80% de probabilidad.
- **Gris:** 15% de probabilidad.
- **Lana:** 5% de probabilidad.

Si la Temperatura es BAJA (ej. 0.1 o 0.2):

La IA se vuelve **determinista**. Siempre elegirá la opción más probable ("**Azul**"). Es ideal para tareas que requieren precisión.

Si la Temperatura es ALTA (ej. 1.0 o más):

La IA "aplana" las probabilidades. Ahora "**Gris**" o incluso "**Lana**" tienen más oportunidad de ser elegidas. Esto hace que la respuesta sea más variada, creativa o sorprendente, pero también aumenta el riesgo de que diga cosas sin sentido (**alucinaciones**).

¿Qué valor elegir?

Valor	Efecto	Uso ideal
0.0 - 0.3	Conservador / Preciso	Generar código, resolver matemáticas, extraer datos de un texto, responder preguntas factuales.
0.7	Equilibrado	Chatbots de propósito general, resúmenes, correos electrónicos. (Es el valor por defecto en casi todos).
1.0 - 1.5	Creativo / Divertido	Escribir poemas, crear historias, lluvia de ideas (brainstorming), juegos de rol.